

2026mid

一、(10 分)

证明两个常用的概率不等式：Markov 不等式和 Chebyshev 不等式。

1. (4 分) 设随机变量 $X \geq 0$, 且 $E[X]$ 存在, 证明 Markov 不等式: 对任意 $a > 0$, $P[X \geq a] \leq \frac{E[X]}{a}$ 。
2. (6 分) 设随机变量 Y 满足 $E[Y]$ 和 $\text{Var}(Y)$ 均存在, 利用 Markov 不等式证明 Chebyshev 不等式: 对任意 $t > 0$, $P[|Y - E[Y]| \geq t] \leq \frac{\text{Var}(Y)}{t^2}$ 。

二、(10 分)

局部敏感哈希 (LSH) 的核心思想是: 距离较近的点应当以较高概率被映射到同一个桶中, 距离较远的点应当以较低概率被映射到同一个桶中。设数据集 $P \subset \mathbb{R}^d$, 查询点为 $q \in \mathbb{R}^d$ 。考虑如下哈希函数:

$$h(u) = \left\lfloor \frac{u \cdot x + t}{T} \right\rfloor, \quad \text{其中 } x \sim N(0, I_d), t \sim U([0, T]).$$

1. (2 分) 请解释该哈希函数的几何含义, 并说明为什么它适合用于近似邻近查询。
2. (2 分) 简要说明为什么在 LSH 查询时, 通常只需要将与查询点 q 发生碰撞的点作为候选邻近进行检查?
3. (3 分) 为了提高查询成功率, 常将多个哈希函数组合成 $g(u) = (h_1(u), h_2(u), \dots, h_k(u))$ 。请说明这种“串联”操作对近似碰撞概率和远点碰撞概率分别有什么影响。
4. (3 分) 为什么在实际算法中, 除了串联多个哈希函数, 还需要建立多张独立的哈希表?

三、(10 分)

设 $X \in \mathbb{R}^{n \times d}$ 为中心化后的数据矩阵。对单位方向 $v \in \mathbb{R}^d$ ，定义数据投影到方向 v 后的投影平方和为 $E(v) = \|Xv\|_2^2$ ，设 $M = X^T X$ ，由于 M 是实对称半正定矩阵。因此 M 存在一组标准正交特征向量 $u_1, \dots, u_d$ ，对应特征值满足 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0$

1. (2 分) 证明 $E(v) = v^T M v$ 。
2. (5 分) 证明在所有单位向量 v 中， $E(v)$ 最大值为 λ_1 ，即 $\max_{\|v\|=1} E(v) = \lambda_1$ 。
3. (3 分) 结合第 2 小问说明在对 X 进行 PCA 降维时，为什么第一主成分方向可以选择 u_1 。

四、(15 分)

JL 变换是一种应用广泛的随机降维方法，设原始数据点位于 $\mathbb{R}^d$ ，目标维度为 k

1. (6 分) 设 $B = \frac{1}{\sqrt{k}}A$ ， $A_{ij} \sim N(0, 1)$ 独立同分布，证明对于任意固定向量 $x \in \mathbb{R}^d$ 有

$$E[\|Bx\|_2^2] = \|x\|_2^2.$$

2. (5 分) 除高斯随机投影外，再给出一种 JL 变换矩阵 $B \in \mathbb{R}^{k \times d}$ 的随机构造方法。
3. (4 分) 简要说明 Fast JL 变换的核心思想。

五、(10 分)

已知 $A = \{x_1, \dots, x_m\} \subset \mathbb{R}^d$ ，其重心为 $\mu = \frac{1}{m} \sum_{x \in A} x$ ，定义

$$\phi_A(c) = \sum_{x \in A} \|x - c\|_2^2, \quad \phi_A^* = \phi_A(\mu),$$

请回答：

1. (5 分) 证明对任意 $c \in \mathbb{R}^d$ ， $\phi_A(c) = \phi_A^* + m\|c - \mu\|_2^2$ ，并推出：若从 A 中均匀随机选择一个点 c ，则 $E[\phi_A(c)] = 2\phi_A^*$ 。
2. (5 分) 解释 K-means++ 为什么不均匀随机选择初始中心，而是采用 D^2 -Sampling。请说明： $D(x)^2$ 表示什么含义？为什么距离已有中心远的点有更大的概率被选中？ D^2 -Sampling 对于提高初始中心质量有什么作用？

六、(10 分)

在 Product Quantization (PQ) 中, 将向量 $u, q \in \mathbb{R}^d$ 分成 m 个子向量:

$$u = [u_1, \dots, u_m], \quad q = [q_1, \dots, q_m],$$

对第 i 个子空间, PQ 用中心 c_i^t 近似 u_i , 用中心 c_i^i 近似 q_i , 记量化误差

$$e_i = u_i - c_i^t, \quad f_i = q_i - c_i^i,$$

假设对所有 i 都有 $\|e_i\|_2 \leq \eta$ 且 $\|f_i\|_2 \leq \eta$ 。

1. (6 分) 证明 PQ 近似平方距离

$$\hat{d}(q, u) = \sum_{i=1}^m \|c_i^t - c_i^i\|_2^2$$

与真实平方距离之间满足

$$|\|u - q\|_2^2 - \hat{d}(q, u)| \leq \sum_{i=1}^m (4\eta \|c_i^t - c_i^i\|_2 + 4\eta^2).$$

2. (4 分) 基于第 1 小问, 解释为什么 PQ 的查询速度和近似误差之间存在联系。预先存储中心距离表能带来什么好处? 量化误差 η 变大时会发生什么?