

19 机器学习方法期末考试

一、训练样本 $\{x_i, y_i\}_{i=1}^n$ 满足线性模型

$$y = X\beta + \epsilon$$

其中 y 为 n 维响应列向量, X 是 $n \times p$ 的列满秩设计矩阵, 误差向量 $\epsilon \sim N_n(0, \sigma^2 I_n)$, 记 β 的最小二乘估计为 $\hat{\beta}$ 。

(1) (8 分) 写出模型参数的似然函数, 比较所求的 β 最大似然估计与 $\hat{\beta}$ 的异同; 求 $\hat{\beta}$ 的分布。

(2) (8 分) 要预测点 x_0 所对应的应变变量 y_0 的值, 满足

$$y_0 = x_0^T \beta + \epsilon_0, \epsilon_0 \sim N(0, \sigma^2)$$

假设 $\text{cov}(\epsilon, \epsilon_0) = 0$, 以 $\hat{y}_0 = x_0^T \hat{\beta}$ 为 y_0 的预报。求: $E(\hat{y}_0 - y_0)^2$

(3) (8 分) 对于给定的 λ 求 $\tilde{\beta}$, 其中

$$\tilde{\beta} = \arg \min_{\beta} \{\|y - X\beta\|^2 + \lambda \beta^T \beta\}$$

(4) (8 分) 分别求最小二乘估计和岭估计方法的有效参数个数。

二、样本 $\{x_i, y_i\}_{i=1}^n$ 满足: $y_i = f(x_i) + \epsilon$, f 的估计方法如下:

$$\hat{f} = \arg \min_f \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int [f''(x)]^2 dx$$

(1) (10 分) (a) 讨论上述方法的模型复杂度是如何把握? (b) 什么情况下模型复杂度最小? 此时 f 取值范围如何? 模型复杂度最大的情形呢?

(2) (10 分) 参数 λ 如何优选, 尽可能细致地讨论一种优选的方法; 该参数的优选与模型的复杂度有怎样的关系?

三、(16 分) 样本 $\{x_i, y_i\}_{i=1}^n$ 满足: $y_i = f(x_i) + \epsilon$ 。写出平方损失下用局部回归方法估计 $f(x_0)$ 的目标函数表达式, 分别求出局部常数和局部线性下的 $f(x_0)$ 估计量表达式。

四、(16 分) 举出一例利用迭代加权最小二乘进行求解的机器学习方法, 并给出求解过程。

五、(16 分) 在训练学习机的过程中维数灾难是怎样表现的?