

25 机器学习方法期末考试

- 一、(1) (5 分) 假设一个三分类问题，分成 A、B、C 三类且三类训练样本数量均相同，分类器学习策略为：预测新样本类别为训练集中的样本数目最多的类别。若用留一法训练，其平均准确率是多少
- (2) (5 分) 给出 LDA 的模型设定；LDA 是 Bayes 分类器吗？是如何进行分类的？求出相应的经验损失函数
- (3) (5 分) 什么是交叉验证和广义交叉验证，讨论二者的主要特点
- (4) (5 分) 在核光滑方法中，窗宽 λ 增大或减小分别如何影响偏差和方差？请结合极端情形说明，并给出实际选择 λ 的方法

- 二、(1) (10 分) 给定样本 $\{x_i, y_i\}_{i=1}^n$ ，建立回归模型

$$f(x) = \beta^T x + b$$

进行拟合。分别给出最小二乘和岭回归下参数估计的表达式，目标函数及估计求解的推导过程，并讨论模型的复杂度

- (2) (10 分) 线性回归模型下，考虑平方损失

(a) 推导乐观度的公式，为什么模型越复杂乐观度越高？

(b) 学习了一个设计矩阵列数为 9 的线性模型，训练误差为 5，样本容量为 100，误差方差为 2，估算真实误差

- 三、(1) (5 分) 选择符合以下的要求的合适的模型（可多选）

(a) 小样本，高噪声预测

(b) 高维变量选择

(c) 强非线性关系

选项：暂无

- (2) (5 分) 从偏差-方差分解的角度，分析以下哪种方法更优并说明原因

(a) 自变量高度共线，目标是预测

(b) 有多个无关变量，目标是变量选择

(c) 样本量很小，变量数中等，关注解释性

选项：OLS、LASSO，岭回归

- (3) (5 分) 从复杂度、可解释性、预测能力三个方面综合比较 OLS、LASSO、Boosting 三种方法

- 四、(1) (4 分) 简述 Bootstrap 方法；Bootstrap 样本中大概有多少个体没被抽到？

- (2) (4 分) 简述 Bagging 方法

- (3) (4 分) 简述局部线性回归较 Nadaraya-Watson 方法在边界处的学习优势
- (4) (4 分) 简述偏差-方差折中的定义, 并说明其在模型选择中的作用, 结合线性回归和 KNN 进行比较
- (5) (4 分) 对正态混合模型进行最大似然估计时, 会遇到怎样的问题? 如何解决?

五、对模型

$$y_i = \mu + \epsilon_i \quad i = 1, \dots, n$$

其中

$$\epsilon_i \sim N(0, \sigma^2) \quad \mu \text{ 有先验分布 } \mu \sim N(\mu_0, \tau^2)$$

- (1) (9 分) 求给定 $\{y_i\}_{i=1}^n$ 时 μ 的后验分布, 当 $n \rightarrow \infty$ 时, μ 的后验均值如何
- (2) (6 分) 推导对于新观测 y_{new} 的预测均方误差

六、(10 分) 设 H 为以 $K(\cdot, \cdot)$ 为再生核的再生核 Hilbert 空间, 观测数据为 $\{x_i, y_i\}_{i=1}^n$, 证明: 目标函数

$$\sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_H^2$$

在 H 中的最小值解 $\hat{f}(\cdot)$ 有形式 $\sum_{i=1}^n K(x_i, \cdot)$