

2017-2018

一、四 相同

极大似然估计 $y = X\beta + \varepsilon$ $\varepsilon \sim N(0, \sigma^2 I_n)$

$$y \sim N(X\beta, \sigma^2 I_n)$$

$$L(\beta) = C \cdot \exp\left\{-\frac{1}{2}(y - X\beta)^T (\sigma^2 I_n)^{-1} (y - X\beta)\right\}$$

取对数 $L(\beta) = C - \frac{1}{2\sigma^2} \|y - X\beta\|^2$

$$\hat{\beta}_{MLE} = \hat{\beta}_{LS} = (X^T X)^{-1} X^T y$$

(2) 有效参数个数看对单元加约束。

$$\hat{y} = X\hat{\beta} = X \underbrace{(X^T X)^{-1} X^T}_H y$$

$$\text{tr}(H) = \text{tr}(X(X^T X)^{-1} X^T) \quad \text{tr}(AB) = \text{tr}(BA)$$

$$= \text{tr}(I_p)$$

$$= p$$

岭回归。X不是列满秩需要加一个惩罚项。

岭回归 X不是列满秩所以小于p
 $\text{rank}(X) < p$ $\text{rank}(X) = \text{rank}(X^T X)$

$$\arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_2^2$$

求得 $\hat{\beta}_{\text{Ridge}} = (X^T X + \lambda I)^{-1} X^T y$

$$\begin{aligned}
& \text{tr} (X \cdot (X^T X + \lambda I)^{-1} X^T) \\
&= \text{tr} (X^T (X + \lambda I)^{-1} X^T X) \\
&= \text{tr} \left(\begin{pmatrix} \frac{1}{d_1 + \lambda} & & \\ & \ddots & \\ & & \frac{1}{d_q + \lambda} & & \\ & & & \ddots & \\ & & & & 0 \end{pmatrix} \begin{pmatrix} d_1 & & \\ & \ddots & \\ & & d_q & & \\ & & & \ddots & \\ & & & & 0 \end{pmatrix} \right) \\
&= \sum_{j=1}^q \frac{d_j}{d_j + \lambda}
\end{aligned}$$

$$(3) \hat{y}_0 = X_0^T \hat{\beta}_{LS} = X_0^T (X^T X)^{-1} X^T y$$

$$E(\hat{y}_0 - y_0)^2 = E(X_0^T \hat{\beta} - X_0^T \beta + \underbrace{X_0^T \beta - y_0}_{\varepsilon_0})^2$$

$$\begin{aligned}
\hat{\beta} - \beta &= (X^T X)^{-1} X^T y - \beta \\
&= (X^T X)^{-1} X^T (X \beta + \varepsilon) - \beta \\
&= \beta + (X^T X)^{-1} X^T \varepsilon - \beta \\
&= (X^T X)^{-1} X^T \varepsilon
\end{aligned}$$

$$\begin{aligned}
\therefore E(\hat{y}_0 - y_0)^2 &= E(X_0^T \hat{\beta} - X_0^T \beta)^2 + b^2 \\
&= E(X_0^T (X^T X)^{-1} X^T \varepsilon)^2 + b^2 \\
&= E X_0^T (X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1} X_0 + b^2 \\
&= X_0^T (X^T X)^{-1} X_0 + b^2 \quad (\text{单位阵})
\end{aligned}$$

二. 对 α 求导.

$$\sum_{i=1}^n k_{\lambda}(x_0, x_i) y_i - \alpha = 0$$

$$\alpha = \frac{\sum_{i=1}^n k_{\lambda}(x_0, x_i) y_i}{\sum_{i=1}^n k_{\lambda}(x_0, x_i)}$$

书上再多写一点, 用交叉验证的方法.

三. 没讲, 但是类似这种书上有讲

四. 书上有.

1)

$$\frac{1}{e}$$

2)

117.119

一. 1) 2) 3) 上 - 张

13) 岭估计 对 β 求导

14) 求 y 的预测

光滑正则 β 与 y 的表达式

有效参数个数和光滑正则 β 的表达式

二. 1) 2) 调节 λ

16) $\lambda=0$ 模型最复杂, 为差值函数.

$\lambda \rightarrow \infty$ 模型最简单, 为线性函数

2)

三. 局部带权最小二乘 - 张二, 1) - 一样.

四. 书上有.
逻辑回归

开卷考试

方法不限在书上写的
位置要正确

五. 维数灾难

2018-2019

一. 条件分布. 贝叶斯

这个题就算比较难的
了.

$$y = x\beta + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$$

$$\beta \sim \mathcal{N}(0, \Sigma) \quad y|\beta \sim \mathcal{N}(x\beta, \sigma^2 I_n)$$

$$P(\beta|y) = \frac{P(y|\beta)P(\beta)}{\int P(y|\beta)P(\beta)d\beta} \propto P(y|\beta)P(\beta)$$

正比
分母无关
 $P(y)$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{i=1}^n P(B|A_i)P(A_i)}$$

$$\mathcal{L} = A_1 + \dots + A_n$$

$$\propto \exp\left\{-\frac{1}{2\sigma^2} (y - x\beta)^T (y - x\beta)\right\} \cdot \exp\left\{-\frac{1}{2} \beta^T \Sigma^{-1} \beta\right\}$$
$$= \exp\left\{-\frac{1}{2\sigma^2} (y^T y + \beta^T x^T x \beta - 2\beta^T x^T y) - \frac{1}{2} \beta^T \Sigma^{-1} \beta\right\}$$

$$\begin{aligned}
& \propto \exp \left\{ -\frac{1}{2} \left[\beta^T \left(\frac{X^T X}{b^2} + \frac{\Sigma^{-1}}{L} \right) \beta - \frac{2}{b^2} \beta^T X^T y \right] \right\} \\
& = \exp \left\{ -\frac{1}{2} (\beta - \mu)^T \left(\frac{X^T X}{b^2} + \frac{\Sigma^{-1}}{L} \right) (\beta - \mu) \right\} \\
& \quad 2 \beta^T \left(\frac{X^T X}{b^2} + \frac{\Sigma^{-1}}{L} \right) \mu = \frac{2}{b^2} \beta^T X^T y \\
& \quad \mu = \frac{1}{b^2} \left(\frac{X^T X}{b^2} + \frac{\Sigma^{-1}}{L} \right)^{-1} X^T y \\
& \quad \beta | y \sim \mathcal{N} \left(\mu, \left(\frac{X^T X}{b^2} + \frac{\Sigma^{-1}}{L} \right)^{-1} \right)
\end{aligned}$$

二. 上节课讲过了. 引导.

三. 估计加权最小二乘.

四. 书上和老师课件都有.

五. 1. 高斯

调节 λ $\rightarrow$ 正则函数

2. 随机森林 老师没讲

线性模型的计算题

简答 $\rightarrow$ 多写一点 不会扣分.